

Détection et Prédiction des Crises d'Épilepsie à partir de Signaux EEG : Approche Hybride LSTM–Transformer avec Analyse Temps-Fréquence (STFT)

1. Introduction

L'épilepsie est une pathologie neurologique caractérisée par la survenue de crises soudaines dues à une activité électrique anormale du cerveau.

Ce projet vise à concevoir une solution complète de prétraitement des signaux EEG et de classification automatique grâce à un modèle hybride LSTM–Transformer. L'accent est mis sur la détection de la phase préictale, essentielle pour anticiper les crises.

2. Prétraitement des données

2.1 Données d'entrée:

Dataset : CHB-MIT (Children's Hospital Boston EEG recordings).

Format : fichiers .edf.

Canaux EEG : 19 électrodes bipolaires (ex. FP1-F7, F7-T7, ..., CZ-PZ).

Fréquence d'échantillonnage : 256 Hz.

Fenêtre temporelle : 1 seconde (256 échantillons).

Chevauchement : 0.5 seconde.

2.2 Annotation et étiquetage:

Chaque fenêtre EEG est classée en trois catégories :

Classe 0 → Interictal : activité normale sans crise.

Classe 1 → Preictal : période de 30 minutes précédant une crise.

Classe 2 → Ictal : période correspondant à une crise en cours.

Les étiquettes sont extraites automatiquement à partir des fichiers d'annotations
.seizures

2.3 Extraction des spectrogrammes:

Pour chaque segment EEG :

Application de la STFT (Short-Time Fourier Transform).

Principe: La STFT découpe le signal en fenêtres temporelles puis calcule le spectre fréquentiel de chaque fenêtre, produisant une matrice temps–fréquence.

Paramètres : $n_{\text{perseg}}=18$, $n_{\text{overlap}}=9 \rightarrow \sim 10$ bandes fréquentielles.

Résultat : tenseur 3D (fréquence \times temps \times canaux) représentant le spectrogramme.

2.4 Équilibrage des classes:

Objectif : 25 000 segments par classe.

Méthodes :

Le nombre d'échantillons étant déséquilibré entre interictal, preictal et ictal, une stratégie est appliquée :

Sous-échantillonnage pour les classes trop nombreuses.

Sur-échantillonnage / augmentation pour les classes rares :

1. Échelle d'amplitude (multiplication par un facteur aléatoire 0.8–1.2).
2. Décalage fréquentiel (jitter).
3. Simulation des états manquants (ex. preictal généré à partir d'interictal avec modulation).

2.5 Sauvegarde:

Format HDF5 compressé :

Dataset spectrograms (spectrogrammes normalisés).


Dataset labels (étiquettes).

Métadonnées : fréquence, canaux, taille de fenêtre.

Sortie : spectrograms_labels_balanced.h5 équilibré, prêt pour l'entraînement.

2.6 Visualisation:

- spectrogram ictal



3. Modélisation et Prédiction (LSTM – Transformer)

3.1 Architecture du modèle hybride

La fonction `create_improved_lstm_transformer_model` définit un réseau hybride LSTM–Transformer optimisé pour les signaux EEG.

a) Entrée

Entrée : tenseur (30, 18, 10) (fréquence × temps × canaux).

Reshape en séquence temporelle: (temps, fréquences × canaux) pour traiter la dimension temporelle.

b) Bloc LSTM

LSTM (96 neurones, dropout 0.25) :

- Capture la dynamique temporelle.
- Recurrent dropout ajouté pour éviter le surapprentissage.

BatchNormalization pour stabiliser l'apprentissage.

c) Bloc Transformer

Projection Dense (128 dimensions) :représente chaque pas temporel

Multi-Head Attention (4 têtes, key_dim = 32)

Permet au modèle d'apprendre les relations globales dans le signal EEG (corrélations entre fréquences ou entre canaux).

Add + LayerNormalization (résidu) : stabilisation.

d) Feed-forward simplifié

Dense(128, activation='relu') + Dropout(0.2):Extraction de caractéristiques non linéaires.

e) Agrégation temporelle

GlobalAveragePooling1D:Résume les informations temporelles en un seul vecteur global.

f) Tête de classification

Dense(64, relu, régularisation L2) + Dropout(0.3)

Dense(3, softmax) → sortie finale : probabilité pour [interictal, preictal, ictal].

Résultat : un modèle efficace , capable de capturer à la fois la dépendance temporelle (LSTM) et les relations globales entre fréquences/canaux (Attention).

3.2 Fonction de coût personnalisée

enhanced_custom_loss combine :

Cross-entropy pondérée:compenser le déséquilibre entre classes et donner plus d'importance au preictal.

Focal Loss simplifiée (gamma = 1.5, alpha = 1.5):

-Se concentre sur les exemples difficiles de la classe préictale.

-Réduit l'impact des échantillons faciles.

3.3 Callback personnalisé

ImprovedPreictalSensitivityCallback : une surcouche d'entraînement qui surveille spécifiquement la sensibilité de la classe préictale.

Après chaque époque, il calcule :Sensibilité (Recall),Précision,F1-score.

Fonctionnalités :

Baseline_epochs = 10 : ignore les 10 premières époques (phase d'échauffement).

Patience = 15, min_delta = 0.01 : arrêt anticipé si pas d'amélioration.

Restauration des meilleurs poids quand la sensibilité préictale est maximale.

⇒ **maximiser la détection préictale**

3.4 Stratégies d'entraînement

Dataset splitting :

Train 68% – Validation 15% – Test 20%.

Split stratifié pour garder les proportions de classes.

Class Weights : {0: 1.0, 1: 3.0, 2: 1.8}.

Optimiseur : Adam (lr initial = 0.0005).

Scheduler : réduction progressive du taux d'apprentissage.

Batch size : 32.

Époques max : 150 (mais arrêt anticipé avec patience)..

3.5 Évaluation

À la fin de l'entraînement, le modèle est évalué sur l'ensemble de test.

Métriques globales :

Accuracy/F1-score (macro et pondéré)/Sensibilité (Recall)/Précision


```
PREICTAL CLASS METRICS:  
Preictal Sensitivity (Recall): 0.9120  
Preictal Precision: 0.9360  
Preictal F1 Score: 0.9238
```

```
=====  
Class: ictal  
  Sensitivity: 0.9120  
  Specificity: 0.9688  
  AUC: 0.9999  
Class: interictal  
  Sensitivity: 0.9120  
  Specificity: 0.9688  
  AUC: 0.9885  
Class: preictal  
  Sensitivity: 0.9120  
  Specificity: 0.9688  
  AUC: 0.9887
```

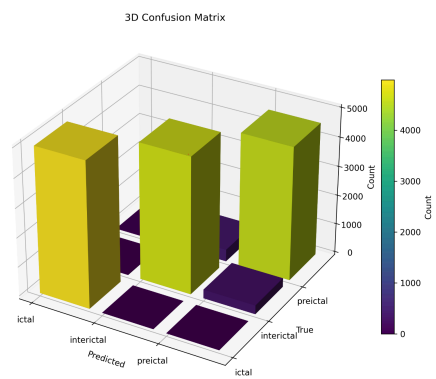
Visualisations générées :

Matrice de confusion.

.2D

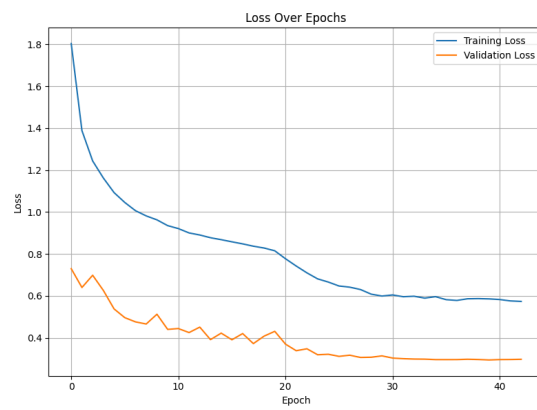


.3D

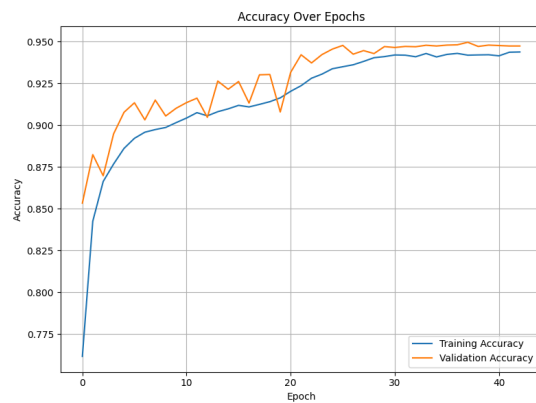


Courbes d'apprentissage


.Loss



.Accuracy



Courbes ROC pour chaque classe.



4. Conclusion

Le modèle LSTM–Transformer présenté constitue une approche hybride et optimisée pour la prédiction de crises d'épilepsie :

1. LSTM :capture la dynamique temporelle locale des signaux EEG.
2. Attention multi-têtes :apprend les relations globales entre fréquences et canaux.
3. Perte personnalisée :oriente l'entraînement vers la classe préictale, cœur du problème.
4. Callback dédié :maximise la sensibilité préictale, critère médical prioritaire.

En combinant ces techniques, le système vise non seulement à classer correctement les signaux EEG, mais surtout à anticiper les crises avec un haut niveau de fiabilité.